



ТЕХНОСФЕРА

Лекция 7 Линейные модели

Кристина Федоренко

14 ноября 2016 г.

План занятия

Линейная регрессия

Логистическая регрессия

Постановка задачи

Дано. Признаковые описания N объектов $\mathbf{x} = (x_1, \dots, x_m) \in \mathcal{X}$, образующие тренировочный набор данных X , и значения целевой переменной $y = f(\mathbf{x}) \in \mathcal{Y}$ для каждого объекта из X .

Найти. Для семейства параметрических функций

$$H = \{h(\mathbf{x}, \theta) = y : \mathcal{X} \times \Theta \rightarrow \mathcal{Y}\},$$

найти значение вектора параметров θ^* , такое что $h^*(\mathbf{x}) = h(\mathbf{x}, \theta^*)$ наилучшим образом приближает целевую функцию.

$\mathcal{Y} \in \{C_1, C_2, \dots, C_K\}$ – задача классификации

$\mathcal{Y} \in [a, b] \subset \mathcal{R}$ – задача регрессии

Линейная регрессия

Дано

Обучающая выборка $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$, где $x_i \in R^d$, $y \in R$.

Найти

Функцию $h : R^d \rightarrow R$, которая предсказывает y по новым x

Гипотеза

$$h(\mathbf{x}, \theta) = \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d = \sum_{j=0}^d \theta_j x_j$$

Базисные функции

Введем функции

$$\phi_j : R^d \rightarrow R^m.$$

$$\phi_j(\mathbf{x}) = (\phi_1(x), \dots, \phi_m(x)).$$

Тогда,

$$h(\mathbf{x}, \theta) = \sum_{j=0}^m \theta_j \phi_j(\mathbf{x}) = \theta^T \phi(\mathbf{x}),$$



$\phi_j(\mathbf{x})$ – базисные функции, $\phi_0(\mathbf{x}) = 1$

Пример. Полиномиальные базисные функции

Пусть $d = 2$, тогда

$$h(\mathbf{x}, \theta) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_1^2 + \theta_5 x_1 x_2$$

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1^2, x_2^2, x_1 x_2)$$



Гауссовская линейная регрессия

Хотим оценить $p(y|\mathbf{x})$.

Предположим, что $p(y|\mathbf{x}) \in p_\phi(y|\mathbf{x})$, где $\phi \in \Phi$.

Задача оценить ϕ по данным \mathcal{D}

Рассмотрим семейство гауссовских функций

$$p_\phi(y|\mathbf{x}) = \mathcal{N}(y|\mu(x), \sigma^2(x)). \quad \phi = (\mu, \sigma^2).$$

Гауссовская линейная регрессия

$$p_\phi(y|\mathbf{x}) = \mathcal{N}(y|\theta^T \mathbf{x}, \sigma^2). \quad \phi = (\theta, \sigma^2), \text{ где } \theta \in R^d, \sigma^2 \in R^+$$

ML – функция правдоподобия

Дана обучающая выборка $\mathcal{D} = (X, Y)$ из N объектов (\mathbf{x}_n, y_n)

Функция правдоподобия

$$\begin{aligned}\log p(Y|\mathbf{x}, \theta, \sigma^2) &= \sum_{n=1}^N \log \mathcal{N}(y|\theta^T \mathbf{x}_n, \sigma^2) = \\ &= \sum_{n=1}^N \log\left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y_n - \theta^T \mathbf{x}_n)^2\right)\right) = \\ &= -\frac{N}{2} \log \sigma^2 - \frac{N}{2} \log 2\pi - \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \theta^T \mathbf{x}_n)^2 \rightarrow \max_{\theta, \sigma}\end{aligned}$$

Квадратичная функция потерь (cost function)

$$J(\theta) = \frac{1}{2} \sum_{n=1}^N (y_n - \theta^T \mathbf{x}_n)^2$$

ML – решение

$$\log p(Y|X, \theta, \sigma^2) = -\frac{N}{2} \log \sigma^2 - \frac{N}{2} \log 2\pi - \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \theta^T \mathbf{x}_n)^2 \rightarrow \max_{\theta, \sigma}$$

Градиент

$$-\frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \theta^T \mathbf{x}_n) \mathbf{x}_n^T = 0$$

Решение

$$\theta_{ML} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}, \quad \sigma^2 = \frac{1}{N} \sum_{n=1}^N (y_n - \theta_{ML}^T \mathbf{x}_n)^2,$$

где

$\mathbf{X} \in R^{n \times d}$ – матрица признаков.

Метод градиентного спуска

Гипотеза

$$h(\mathbf{x}, \theta) = \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d = \sum_{j=0}^d \theta_j x_j$$

Параметры

$$\theta = (\theta_1, \dots, \theta_d)$$

Функция потерь $J(\theta) = \frac{1}{2} \sum_{n=1}^N (y_n - \theta^T \mathbf{x}_n)^2$

Градиентный спуск

Repeat {

$$\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

}

Градиентный спуск

```
1 function gd(J, alpha, epsilon):  
2     initialise theta  
3     do:  
4         theta = new_theta  
5         new_theta = theta - alpha*grad(theta)  
6     until dist(new_theta, theta) < epsilon  
7     return theta
```

Если нужно быстрее, то Stochastic Gradient Descent(SGD)

Логистическая регрессия

Гипотеза


$$h(\mathbf{x}, \theta) = g(\theta^T \mathbf{x})$$

Сигмоида

$$g(z) = \frac{1}{1 + \exp(-z)}.$$

Тогда,

$$\hat{p}(y = 1 | \mathbf{x}, \theta) = h(\mathbf{x}, \theta) = \frac{1}{1 + \exp(-\theta^T \mathbf{x})}$$



Упражнение

X_1	X_2
0	1
1	0
1	1
2	2
2	3
3	2

Определите к какому классу относятся наблюдения, если вектор параметров имеет вид $(\theta_0 = 0.2, \theta_1 = 0.1, \theta_2 = 0.1)$

Функция потерь для логистической регрессии

Обучающая выборка

$\mathcal{D} = (X, Y)$ из N объектов (\mathbf{x}_n, y_n) , где $x_i \in R^d$, $y \in \{0, 1\}$.

Гипотеза

$$h(\mathbf{x}, \theta) = \frac{1}{1 + \exp(-\theta^T \mathbf{x})}$$

Функция потерь для одного наблюдения

$$\text{cost}(y, h(\mathbf{x}, \theta)) = -y \log(h(\mathbf{x}, \theta)) - (1 - y) \log(1 - h(\mathbf{x}, \theta))$$

Функция потерь для логистической регрессии

Функция потерь для выборки

$$J(\theta) = \frac{1}{N} \sum_{n=1}^N \text{cost}(y_n, h(\mathbf{x}_n, \theta)) = \frac{1}{N} \sum_{n=1}^N -y_n \log(h(\mathbf{x}_n, \theta)) - (1 - y_n) \log(1 - h(\mathbf{x}_n, \theta))$$

Частная производная по θ_j

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{N} \sum_{n=1}^N (h(\mathbf{x}_n, \theta) - y_n) x_n^j$$

Градиентный спуск для логистической регрессии

Частная производная по θ_j

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{N} \sum_{n=1}^N (h(\mathbf{x}_n, \theta) - y_n) x_n^j$$

Градиентный спуск

Repeat {

$$\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta) = \theta_j - \alpha \frac{1}{N} \sum_{n=1}^N (h(\mathbf{x}_n, \theta) - y_n) x_n^j$$

}

Регуляризация

Функция потерь

$$J_R(\theta, \lambda) = J(\mathbf{w}) + \lambda \sum_{n=1}^N |\mathbf{w}_n|^q,$$

где для линейной регрессии

$$J(\theta) = \frac{1}{2} \sum_{n=1}^N (y_n - \theta^T \mathbf{x}_n)^2,$$

для логистической регрессии

$$J(\theta) = \frac{1}{N} \sum_{n=1}^N -y_n \log(h(\mathbf{x}_n, \theta)) - (1 - y_n) \log(1 - h(\mathbf{x}_n, \theta))$$

Виды регуляризации

- ▶ $q = 1$ – Lasso
- ▶ $q = 2$
- ▶ $\rho \sum_{n=1}^N |\mathbf{w}_n| + (1 - \rho) \sum_{n=1}^N \mathbf{w}_n^2$ – Elastic Net

Мультикласс классификация

- ▶ one-vs-rest

Строим K моделей, каждая соответствует одному классу


- ▶ one-vs-one

Строим $K(K - 1)/2$ моделей, каждая соответствует паре классов

Ирисы Фишера



Setosa



Versicolor





Virginica

Задача

Определить вид ириса на основании длины чашелистика, ширины чашелистика, длины лепестка и ширины лепестка.

Ирисы Фишера



Вопросы

